

Алгоритмы кластеризации крупномасштабных однодольных и двудольных графов на основе модели СРМ и вероятностных функций издержек

Часть 1. Обзор литературы и постановка задачи

Введение

Задача выявления структуры сообществ (community detection) является одной из центральных задач анализа графов и сетевых данных. Ее практическая значимость обусловлена широким спектром приложений, включающих анализ социальных сетей, биоинформатику, телекоммуникационные системы, рекомендательные сервисы и информационный поиск. В большинстве современных постановок задача сводится к поиску такого разбиения множества вершин графа на кластеры, которое максимизирует некоторую функцию качества, характеризующую плотность связей внутри сообществ и разреженность связей между ними.

Одной из наиболее эффективных функций качества является Constant Potts Model (СРМ). В отличие от классической модулярности Ньюмана–Гирвана, СРМ не обладает проблемой ограничения разрешения (resolution limit), вследствие чего способна выявлять как крупные, так и относительно небольшие сообщества. Данное свойство особенно важно при анализе реальных сетей, содержащих группы существенно различающихся размеров.

Формальная постановка задачи

Пусть задан неориентированный граф $G=(V,E)$, где V — множество вершин, а E — множество рёбер. Требуется найти разбиение множества вершин $C=(C_1,\dots,C_k)$, максимизирующее функцию качества СРМ:

$$H(C)=\sum_{i=1..k} (W(C_i) - \gamma \cdot |C_i|(|C_i|-1)/2).$$

Здесь $W(C_i)$ — суммарный вес рёбер между вершинами кластера C_i , $|C_i|$ — число вершин в кластере, а $\gamma>0$ — параметр разрешения.

Параметр γ определяет минимальную плотность связей внутри сообщества. В результате оптимизации формируются кластеры, для которых внутренняя плотность связей превышает заданный порог, тогда как межкластерные связи остаются относительно редкими.

Следует отметить, что максимизация СРМ является вычислительно сложной задачей. Для графов, содержащих миллионы вершин и миллиарды рёбер, применение точных методов оптимизации оказывается практически невозможным, что обуславливает необходимость использования эвристических алгоритмов.

Основные направления исследований

Современные методы оптимизации CPM можно условно разделить на несколько основных классов.

- Локальный поиск: алгоритмы последовательно улучшают текущее разбиение путём перемещения отдельных вершин между кластерами.
- Многоуровневые методы: граф последовательно сжимается посредством объединения вершин одного сообщества в суперузлы.
- Инкрементальная кластеризация: алгоритмы обновляют существующее разбиение при изменении графа без полного перерасчёта.

Современное состояние области

На протяжении длительного времени наиболее популярным алгоритмом обнаружения сообществ оставался алгоритм Лувена (Louvain Method). Его работа состоит из двух этапов: локальной оптимизации функции качества и последующей агрегации найденных сообществ в суперузлы.

Несмотря на высокую эффективность, алгоритм Лувена обладает существенным недостатком: получаемые сообщества могут оказаться внутренне несвязными. Это приводит к снижению интерпретируемости результатов и ухудшению качества кластеризации.

Для устранения данного недостатка был предложен алгоритм Лейдена (Leiden Algorithm), который в настоящее время рассматривается как один из наиболее эффективных методов оптимизации CPM. Введение дополнительной фазы уточнения позволяет гарантировать связность формируемых сообществ и одновременно улучшает качество найденного разбиения.

Альтернативные функции качества

Помимо CPM, в литературе широко используются и другие критерии качества кластеризации.

- Модулярность (Modularity) — классическая метрика качества сообществ, однако она склонна объединять небольшие хорошо отделимые кластеры.
- Infomap — метод, основанный на теории информации; он минимизирует длину описания случайного блуждания по графу.
- Спектральная кластеризация — подход, использующий собственные значения и собственные векторы матрицы Лапласиана графа.

Известно, что задача максимизации CPM является NP-трудной. Более того, даже построение решений с гарантированным постоянным коэффициентом приближения представляет существенную вычислительную сложность. По этой причине практически все современные методы обнаружения сообществ основаны на эвристических процедурах.

Одним из наиболее актуальных направлений исследований остаётся разработка распределённых версий многоуровневых алгоритмов, обеспечивающих эффективную работу на вычислительных кластерах без ухудшения качества кластеризации.

Часть 2. Анализ алгоритма Лейдена

Исходная публикация

Traag, V. A., Waltman, L., & van Eck, N. J. (2019). From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 9(1), 5233.

Общая идея алгоритма

Алгоритм Лейдена представляет собой развитие алгоритма Лувена и предназначен для устранения проблемы несвязных сообществ. Основная идея заключается в чередовании локальной оптимизации, уточнения структуры кластеров и агрегации графа.

Каждая итерация алгоритма состоит из трёх последовательных фаз.

- Фаза локального перемещения вершин: каждая вершина рассматривается независимо, и её перемещение в соседние кластеры оценивается по изменению функции качества.
- Фаза уточнения: внутри каждого сообщества ищутся более плотные подструктуры, что позволяет устранить слабосвязные компоненты.
- Фаза агрегации: каждое найденное сообщество заменяется суперузлом, после чего формируется новый укрупнённый граф.

Вычислительная сложность

Теоретический анализ алгоритма затруднён вследствие его эвристической природы. Тем не менее для разреженных графов, характерных для социальных сетей, наблюдается практически линейная зависимость времени работы от числа рёбер: $O(|E|)$. Использование компактных структур хранения графов обеспечивает потребление памяти порядка $O(|V| + |E|)$.

На практике алгоритм Лейдена обычно демонстрирует более высокую скорость сходимости по сравнению с алгоритмом Лувена.

Теоретические гарантии

В работе авторов доказано, что сообщества, сформированные алгоритмом Лейдена, являются связными в исходном графе. Кроме того, показано, что итоговое разбиение удовлетворяет ряду локальных оптимизационных свойств, отсутствующих у алгоритма Лувена.

Данные результаты делают Лейден одним из немногих методов обнаружения сообществ, для которого существуют строгие теоретические гарантии качества получаемой структуры.

Параллельная реализация

Высокая вычислительная эффективность алгоритма делает его привлекательным для параллельных вычислений. Одним из распространённых подходов является использование раскраски графа. Вершины одного цвета не имеют общих рёбер и могут обрабатываться параллельно без возникновения конфликтов доступа к памяти.

Практическая значимость данного подхода подтверждается включением реализации алгоритма Лейдена в библиотеку GPU-аналитики RAPIDS cuGraph, разработанную компанией NVIDIA.

Часть 3. Кластеризация двудольного графа на основе вероятностной функции издержек

Постановка задачи

Рассмотрим взвешенный двудольный граф $G=(A \sqcup B, E)$, где множество A соответствует источникам сигналов, а множество B — сенсорам.

Требуется построить разбиение множества источников $C=(C_1, \dots, C_k)$, минимизирующее вероятность повреждения сенсоров и одновременно ограничивающее число формируемых кластеров.

Вероятностная модель

Пусть $S_u \subseteq A$ обозначает множество источников, связанных с сенсором u .

Вероятность того, что ни один источник из кластера C_i не активирует сенсор u , определяется выражением:

$$q_{\{u,i\}} = \prod_{v \in S_u \cap C_i} (1 - p_{\{v,u\}}).$$

Сенсор остаётся работоспособным в двух случаях: (1) ни один источник не отправил сигнал; (2) сигналы поступили только от источников одного кластера.

Тогда вероятность безопасного функционирования сенсора равна:

$$P_{\text{safe}}(u) = \prod_{i=1}^k q_{\{u,i\}} + \sum_{j=1}^k [(1 - q_{\{u,j\}}) \cdot \prod_{i \neq j} q_{\{u,i\}}].$$

Вероятность отказа сенсора определяется как $l_u(C) = 1 - P_{\text{safe}}(u)$.

Итоговая функция издержек имеет вид:

$$L(C) = \sum_{u \in B} l_u(C) + \alpha k,$$

где параметр α регулирует компромисс между качеством кластеризации и числом сформированных кластеров.

Алгоритм DBLS

Для решения поставленной задачи предлагается алгоритм Distributed Bipartite Local Search (DBLS). В отличие от методов, использующих однодольную проекцию двудольного графа, DBLS работает непосредственно с исходной структурой данных. Это позволяет избежать квадратичного роста числа рёбер и связанных с ним проблем масштабируемости.

Алгоритм включает следующие этапы:

- Инициализация, при которой каждый источник образует отдельный кластер.
- Поддержание разреженных структур вероятностей $q_{\{u,i\}}$ для всех сенсоров.
- Вычисление локального изменения функции издержек при переносе вершины между кластерами.

- Выполнение перемещения, если оно приводит к уменьшению значения $L(C)$.
- Повторение процесса до достижения локального минимума.

Поскольку изменение стоимости затрагивает только сенсоры, непосредственно связанные с перемещаемым источником, стоимость одного локального обновления пропорциональна степени рассматриваемой вершины.

Обработка высокостепенных сенсоров

На практике в графах могут присутствовать сенсоры с чрезвычайно высокой степенью. Такие вершины создают значительную вычислительную нагрузку и оказывают ограниченное влияние на итоговое разбиение. Поэтому предлагается вводить порог τ и исключать сенсоры со степенью выше данного значения из локальных вычислений. Подобная процедура позволяет существенно ускорить работу алгоритма без заметного ухудшения качества решения.

Оценка сложности

При использовании разреженных структур данных одна итерация алгоритма имеет вычислительную сложность $O(|E|)$. Требуемый объём памяти оценивается как $O(|V| + |E| + |A| \cdot k_{avg})$, где k_{avg} обозначает среднее число кластеров, влияющих на один источник.

Использование инструментов искусственного интеллекта

Инструменты искусственного интеллекта использовались для подготовки предварительной версии текста, восстановления математических формул по исходному описанию задачи и автоматизации процесса оформления отчёта.

Предложенная в части 3 вероятностная модель и концепция алгоритма DBLS основаны на общих принципах теории графов, вероятностного моделирования и методов локального поиска. Все математические выкладки и алгоритмические решения были дополнительно проверены на логическую согласованность и соответствие поставленной задаче.